

PEC1 - Anàlisi de Dades òmiques

Joan Fillol Pastor

2 de abril, 2025

Contents

ABSTRACT	1
OBJECTIUS	1
MÈTODES	1
RESULTATS	2
Seleccionar i descarregar el dataset	2
Carregar i acumular les dades	2
Anàlisi exploratori de les dades	2
Visualitzar les dades	2
Selecció de metabolits	3
PCA	4
Preparació de les dades per a PCA	4
Realització del PCA	4
DISCUSSIÓ	8
CONCLUSIONS	8
REFERENCIES	8

ABSTRACT

OBJECTIUS

L'objectiu d'aquest treball es identificar patrons en els perfils metabòlics urinaris de pacients en càncer que no siguin presents en pacients no afectat o en afectacions benignes, els quals permetin ser una eina de diagnòstic ràpid per a aquesta afectació.

MÈTODES

Per a la elaboració del anàlisi exposant en aquest informe s'ha usat dades publicades com un article obert (Chan et al. 2015). Les dades desconvolades i anotades es troben al Metabolomics Workbench data repository, sota el Project ID PR00699. Les dades es poden accedir de forma directa via el projecte a <http://dx.doi.org/DOI:10.21228/M8B10B>.

Aquestes dades, estan compreses per l'estudi H1-RMN dels perfils metabòlics urinaris de diferents grups de pacients amb càncer gàstric, en específic pacients amb càncer gàstric (GC), pacients amb malalties gàstriques benignes (BN) i pacients no afectats (HE).

Per a estudiar aquestes dades, s'ha usat el paquet *Bioconductor* [], del qual s'han usat els paquets *Biobase* i *SummarizedExperiment* (Morgan et al. 2024) per a la construcció d'un objecte amb la classe homònima d'aquest paquet.

A més a més, també s'han usat

RESULTATS

Seleccionar i descarregar el dataset

El dataset que es vol usar és el que respecta al càncer gàstric, el es carrega a partir del fitxer *xlsx* disponible en el repositori GitHub del informe.

```
library(readxl)

#obtenir l'estudi en qüestió en forma de df a partir del fitxer xlsx
raw = read_xlsx('GastricCancer_NMR.xlsx')
```

Carregar i acumular les dades

Per a carregar i acumular les dades s'usa un objecte de classe *SummarizedExperiment*. Aquesta classe s'usa per a acumular matrius rectangulars de resultats experimentals, sent possible acumular resultats de diferents experiments sempre que siguin de dimensions iguals. Cadascun dels objectes acumula observacions d'una o més mostres, a més a més de la *metadata* descriptora de les observacions (*features*) i de les mostres (*fenotips*).

Un aspecte clau d'aquest tipus de classes és la capacitat de mantenir lligades les dades experimentals a les metadades, el que permet realitzar transformacions a les dades experimentals, com per exemple eliminar una *feature* o normalitzar un resultat, sense perdre les metadades que van lligades a aquestes dades experimentals.

Aquesta classe és una extensió de la classe base de *Bioconductor* *ExpressionSet*. La principal diferència que presenta la classe extesa sobre la original és la flexibilitat pel que respecta la formació de files, permetent la formació de files tant en elements *GRange* com sobre elements descrits per *DataFrame*s arbitraris. Això permet molta més flexibilitat en l'utilització i la fa una classe molt adequada per a una gran varietat d'usos a la bioinformàtica.

```
#carregar la llibreria metabolomics Workbench R i summarizedExperiment
library("metabolomicsWorkbenchR")
library('SummarizedExperiment')

#classificar les dades com a summarizedExperiment
df <- SummarizedExperiment(assays = list(raw[,5:153]))

#afegir les metadades al element summarized experiment
rowData(df) <- data.frame(Idx = raw[,1], SampleID = raw[,2], Sampletype = raw[,3], SampleClass = raw[,4])
```

Anàlisi exploratori de les dades

Visualitzar les dades

El primer pas doncs en l'anàlisi exploratori de les dades és visualitzar-les, per a conèixer'n la forma i les característiques principals. El primer que cal visualitzar és l'element *SummarizedExperiment*, el qual pot posar informació clau sobre les dades.

```
#es visualitza la informació del Summarized Experiment
cat('Resum del element Summarized Experiment per a les dades inicials: \n')
```

```
## Resum del element Summarized Experiment per a les dades inicials:
```

```
df
```

```
## class: SummarizedExperiment
## dim: 140 149
## metadata(0):
## assays(1): ''
## rownames(140): 1 2 ... 139 140
## rowData names(4): Idx SampleID SampleType Class
## colnames(149): M1 M2 ... M148 M149
## colData names(0):
```

En aquesta sortida de consola es pot veure que la informació numèrica del assaig es troba dins d'un assaig sense nom. Cal doncs, accedir a aquest assaig per a visualitzar-ne les dades (només les primeres entrades) i fer-ne un breu resum.

```
#s'extreuen les dades del Summarized Experiment
dades = assay(df)
#es visualitza un breu resum i una breu mostra de les 5 primeres entrades de les dades
head(dades[1:5,1:5]) %>% kableExtra::kable()
```

	M1	M2	M3	M4	M5
	90.1	491.6	202.9	35.0	164.2
	43.0	525.7	130.2	NA	694.5
	214.3	10703.2	104.7	46.8	483.4
	31.6	59.7	86.4	14.0	88.6
	81.9	258.7	315.1	8.7	243.2

```
summary(dades[1:5]) %>% kableExtra::kable()
```

M1	M2	M3	M4	M5
Min. : 0.40	Min. : 3.1	Min. : 0.1	Min. : 0.10	Min. : 1.3
1st Qu.: 29.82	1st Qu.: 140.9	1st Qu.: 53.6	1st Qu.: 18.77	1st Qu.: 67.0
Median : 60.35	Median : 270.2	Median :105.1	Median : 35.70	Median : 160.3
Mean :101.07	Mean : 642.0	Mean :146.4	Mean : 43.83	Mean : 231.1
3rd Qu.:133.38	3rd Qu.: 480.9	3rd Qu.:198.8	3rd Qu.: 51.33	3rd Qu.: 253.1
Max. :909.90	Max. :26195.8	Max. :862.5	Max. :242.50	Max. :2503.0
NA's :16	NA's :1	NA's :7	NA's :12	NA's :2

En aquestes taules es poden veure les primeres entrades de les dades i un breu resum d'aquestes.

Com es pot veure a la taula de resum, alguns dels metabolits present valors no existents, **NA**. Per a filtrar els metabolits considerats com a bons doncs, es passa un control de qualitat sobre les dades.

Selecció de metabolits

Per a poder treballar amb metabolits que ens aportin informació, cal que el màxim nombre de variables tinguin informació disponible per al metabolit en qüestió. Per a assegurar-nos d'això, s'eliminen els metabolits on els valors **NA** representen més d'un 10% dels valors totals.

```
## Resum de les dades seleccionades:

## class: SummarizedExperiment
## dim: 140 122
## metadata(0):
```

```
## assays(1): ''
## rownames(140): 1 2 ... 139 140
## rowData names(4): Idx SampleID SampleType Class
## colnames(122): M2 M3 ... M148 M149
## colData names(0):
```

Com es pot veure a la sortida de consola on es veu el resum del nou element *SummarizedExperiment*, de les 149 variables que posseïa el dataset original se'n conserven 122, sent aquestes les que els valors NA representen menys d'un 10% de les dades.

PCA

Preparació de les dades per a PCA

Per a estudiar quins dels components tenen un efecte més clar sobre la afectació o no dels pacients, es realitza un PCA sobre les dades.

Degut a que el PCA necessita totes les dades per a treballar, les dades que falten (**NA**) es generen mitjançant un algoritme predictiu KNN amb 3 veïns. Això és necessari degut a que per al anàlisi dels components principals no poden haver-hi elements amb valors perduts. Per a això, s'usa el paquet *multiUS* (Torgo 2011).

```
## El numero de valors NA al dataset filtrat és de: 391
##
## El numero de valors NA al dataset imputat és de: 0
```


Com es pot veure a la sortida de consola, imputar el dataset permet eliminar els valors NA de les dades. Això és necessari per a realitzar el PCA.

Per al PCA, també es important normalitzar les dades, ja que el PCA és un exercici de maximització de la variància. Sense normalització, el PCA seleccionaria les variables amb més variància interna, no aquelles que representen de veritat la variació del resultat.

Realització del PCA

Amb les dades preparades, es pot realitzar el PCA. Per a visualitzar-ne els resultats, s'usa el paquet *factoextra* (Kassambara and Mundt 2020).


```
#realitzar el PCA
pca <- princomp((assay(df_pca_norm)))
```




En el grafic *Scree* resultant del PCA es pot veure com el primer factor representa més del 25% de la variació de les dades, el que aporta informació important. Juntament amb el segon factor, aporten més del 35% de la informació.

El següent pas es analitzar com estan organitzats aquests factors.


```
fviz_contrib(pca, choice = "var", axes = 1, top = 10)
```



```
fviz_contrib(pca, choice = "var", axes = 2, top = 10)
```



En aquests dos gràfics es pot veure les 10 variables que més influeixen en cadascun dels dos primers components.



En aquest grafic, es pot veure com els dos primers components separen les dades de les diferents

DISCUSSIÓ

CONCLUSIONS

REFERENCIES

- Chan, Angela W, Pascal Mercier, Daniel Schiller, Robert Bailey, Sarah Robbins, Dean T Eurich, Michael B Sawyer, and David Broadhurst. 2015. "1H-NMR Urinary Metabolomic Profiling for Diagnosis of Gastric Cancer." *British Journal of Cancer* 114 (1): 59–62. <https://doi.org/10.1038/bjc.2015.414>.
- Kassambara, A, and F Mundt. 2020. "Factoextra: Extract and Visualize the Results of Multivariate Data Analyses." *The Comprehensive R Archive Network*. Comprehensive R Archive Network (CRAN). <https://CRAN.R-project.org/package=factoextra>.
- Morgan, Martin, Valerie Obenchain, Jim Hester, and Hervé Pagès. 2024. "SummarizedExperiment: A Container (S4 Class) for Matrix-Like Assays." *Bioconductor*. <https://doi.org/doi:10.18129/B9.bioc.SummarizedExperiment>.
- Torgo, Luis. 2011. *Data Mining with R*, September. <https://doi.org/10.1201/9780429292859>.